МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра математического обеспечения и применения ЭВМ

ОТЧЕТ

по лабораторной работе 3

по дисциплине «Искусственные нейронные сети»

Тема: «Регрессионная модель изменения цен на дома в Бостоне»

Студентка гр. 7383 _____ Прокопенко Н.

Преподаватель _____ Жукова Н.А.

Санкт-Петербург

2020

Цель работы.

Реализовать предсказать медианной цены на дома в пригороде Бостона в середине 1970-х по таким данным, как уровень преступности, ставка местного имущественного налога и т.д.

Данный набор содержит относительно немного образцов данных: всего 506, разбитых на 404 обучающих и 102 контрольных образца. И каждый признак во входных данных (например, уровень преступности) имеет свой масштаб. Например, некоторые признаки являются пропорциями и имеют значения между 0 и 1, другие – между 1 и 12 и т. д.

Порядок выполнения работы.

1. Ознакомиться с задачей регрессии;
2. Изучить отличие задачи регрессии от задачи классификации;
3. Создать модель;
4. Настроить параметры обучения;
5. Обучить и оценить модели;
6. Ознакомиться с перекрестной проверкой.

Требования.

1. Объяснить различия задач классификации и регрессии;
2. Изучить влияние кол-ва эпох на результат обучения модели;
3. Выявить точку переобучения;
4. Применить перекрестную проверку по K блокам при различных K;
5. Построить графики ошибки и точности во время обучения для моделей, а также усредненные графики по всем моделям.

Ход работы.

Классификация – один из разделов машинного обучения, посвященный решению следующей задачи. Имеется множество объектов (ситуаций), разделённых некоторым образом на классы. Задано конечное множество

объектов, для которых известно, к каким классам они относятся. Это множество называется обучающей выборкой. Классовая принадлежность остальных объектов не известна. Требуется построить алгоритм, способный классифицировать произвольный объект из исходного множества.

Классифицировать объект – значит, указать номер (или наименование класса), к которому относится данный объект.

Другим распространенным типом задач машинного обучения является регрессия, которая заключается в предсказании не дискретной метки, а значения на непрерывной числовой прямой: например, предсказание температуры воздуха на завтра по имеющимся метеорологическим данным или предсказание времени завершения программного проекта по его спецификациям.

Для изучения регрессионной модели ИНС была разработана программа, код представлен в приложении А.

Была рассмотрена модель с перекрестной проверкой по K блокам (K-fold cross-validation) при `k` = 4 и `epochs` = 400. Графики оценки `mae` для каждого блока приведены на рис. 1. График средних значений `mae`, приведен на рис. 2.

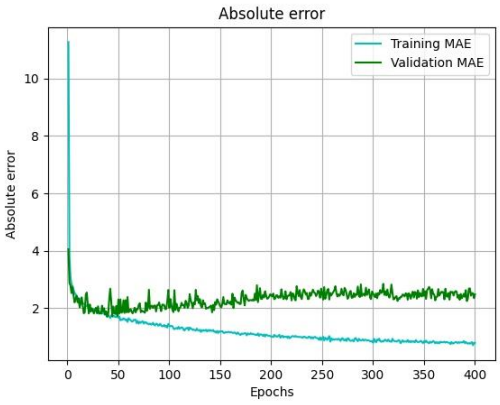

(а)

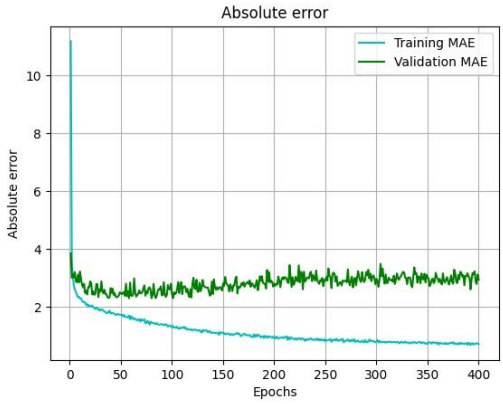

(б)

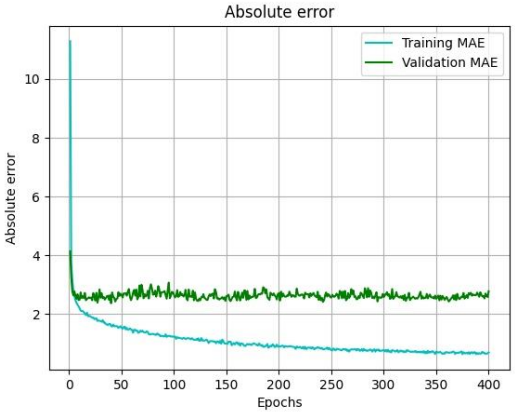

(в)

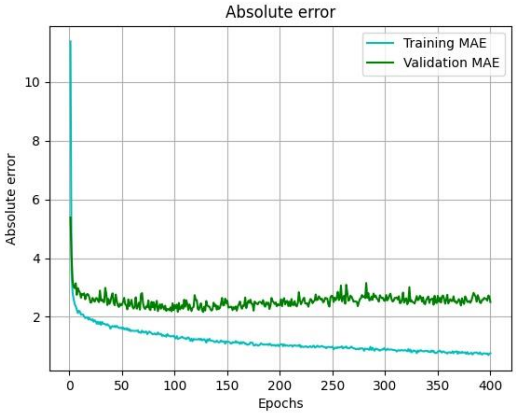

(г)

Рисунок 1 – График оценки mae для блоков: (а) 1, (б) 2, (в) 3, (г) 4

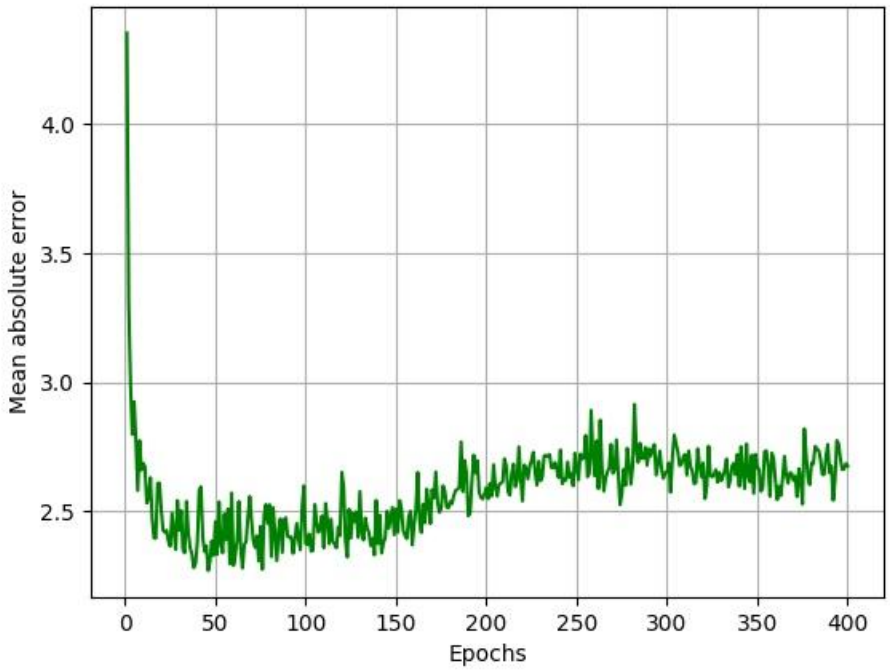

Рисунок 2 – График среднего значения mae (модель: k = 4 и epochs = 400).

Из графика (рис. 2) замечено, что mae на проверочных данных уменьшается до 50 эпох обучения, после она либо не меняется, либо увеличивается, тогда как на тестовых данных оно продолжает уменьшаться.

Это связано с переобучением нейронной сети, поэтому за оптимальное число эпох берётся 50.

При заданном числе эпох было рассмотрено среднее значение оценки

mae при k = 2, 4, 6 и 8 блокам для перекрестной проверки. Результаты приведены на графиках, показанных на рис. 3.

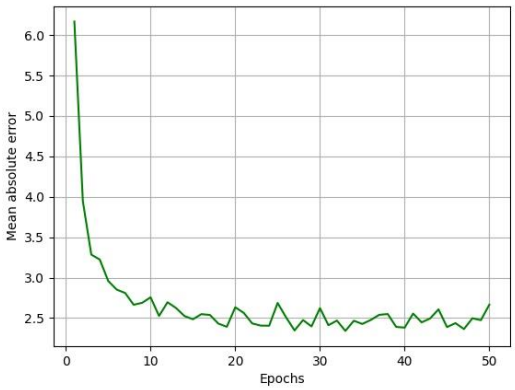

(а)

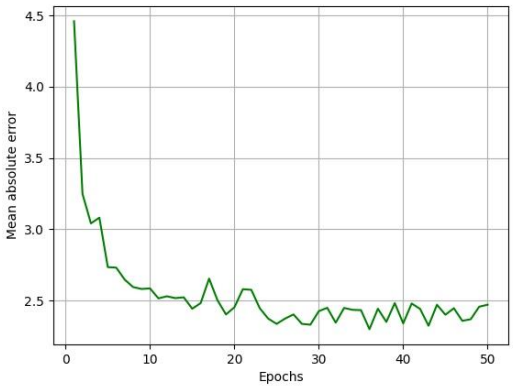

(б)

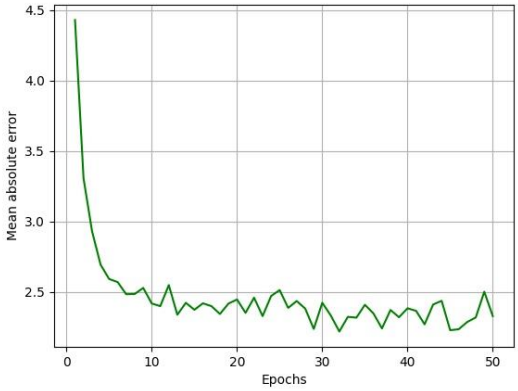

(в)

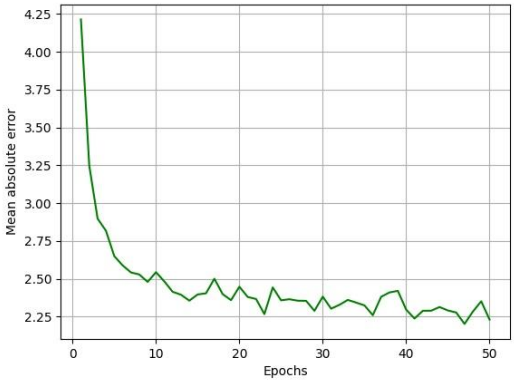

(г)

Рисунок 3 – График среднего значения mae для моделей с: (а) 2 блоками, (б) 4 блоками, (в) 6 блоками, (г) 4 блоками

По графикам (рис. 3) видно, что наилучшее значение средней оценки mae достигается в модели, использующей 8 блоков перекрестной проверки (рис. 3 (г)), а наихудшее значение – в модели с 2 блоками перекрестной проверки (рис. 3 (а)).

Выводы.

В ходе выполнения лабораторной работы было изучено влияние количества эпох и количества блоков в перекрестной проверке по K на

результат обучения модели искусственной нейронной сети, решающей задачу регрессии.

Также была выбрана оптимальная модель: при k = 8 и epochs = 50.

ПРИЛОЖЕНИЕ А

```
import numpy as np

from tensorflow.keras.layers import Dense

from tensorflow.keras.models import Sequential

import matplotlib.pyplot as plt

from tensorflow.keras.datasets import boston_housing

# Загрузка набора данных для Бостона

(train_data, train_targets), (test_data, test_targets) =
boston_housing.load_data()

# Вывод данных для просмотра

print(train_data.shape)                                    # 404
обучающих образца с 12 числовыми признаками

print(test_data.shape)                                     # 102
контрольных образца с 12 числовыми признаками

print(test_targets)                                        # Цели –
медианные значения цен на дома, занимаемые собственниками, в тысячах
долларов

# Нормализация данных

mean = train_data.mean(axis=0)

std = train_data.std(axis=0)

train_data -= mean

train_data /= std

test_data -= mean

test_data /= std

# Определение (создание) модели

def build_model():

    model = Sequential()

    model.add(Dense(64, activation='relu',
input_shape=(train_data.shape[1],)))

    model.add(Dense(64, activation='relu'))

    model.add(Dense(1))

    model.compile(optimizer='rmsprop', loss='mse', metrics=['mae'])
```

```
        return model
    # mse - среднеквадратичная ошибка
    # mae - средняя абсолютная ошибка
    # K-fold cross-validation
    k = 8
    num_val_samples = len(train_data) // k
    num_epochs = 50
    all_scores = []
    mae_histories = []
    for i in range(k):
        print('processing fold #', i)
        # Подготовка проверочных данных: данных из блока с номером k
        val_data = train_data[i * num_val_samples: (i + 1) *
num_val_samples]
        val_targets = train_targets[i * num_val_samples: (i + 1) *
num_val_samples]

        # Подготовка обучающих данных: данных из остальных блоков
        partial_train_data = np.concatenate([train_data[:i *
num_val_samples],
                                             train_data[(i + 1) *
num_val_samples:]], axis=0)
        partial_train_target = np.concatenate([train_targets[: i *
num_val_samples],
                                               train_targets[(i + 1) *
num_val_samples:]], axis=0)
        # Конструирование модели Keras (уже скомпилированной)
        model = build_model()

        # Обучение модели (в режиме без вывода сообщений, verbose = 0)
        history = model.fit(partial_train_data, partial_train_target,
epochs=num_epochs, batch_size=1,
```

```
                              validation_data=(val_data, val_targets))
        mae = history.history['mae']
        v_mae = history.history['val_mae']
        x = range(1, num_epochs + 1)
        mae_histories.append(v_mae)
        plt.figure(i + 1)
        plt.plot(x, mae, 'c', label='Training MAE')
        plt.plot(x, v_mae, 'g', label='Validation MAE')
        plt.title('Absolute error')
        plt.ylabel('Absolute error')
        plt.xlabel('Epochs')
        plt.legend()
        plt.grid()
    # Создание истории последовательных средних оценок проверки  по K блокам
    average_mae_history = [np.mean([x[i] for x in mae_histories]) for i in range(num_epochs)]
    # Сохранение результатов в файл
    plt.figure(0)
    plt.plot(range(1, num_epochs + 1), average_mae_history, 'g')
    plt.xlabel('Epochs')
    plt.ylabel("Mean absolute error")
    plt.grid()
    figs = [plt.figure(n) for n in plt.get_fignums()]
    for i in range(len(figs)):
            figs[i].savefig("./%d.png" %(i), format='png')
```